

DATA ENGINEERING PORTFOLIO

ETL Pipeline Design E-Commerce Orders

Extract → Transform → Validate → Load, dengan orchestration dan production-ready Airflow DAG.

Yazitzy

Workshop: ETL Architecture, Orchestration & Career Advancement

130 → 110

baris diproses

5 / 5

quality check passed

Rp 562,5jt

total revenue

Masalah Data & Tujuan Pipeline



Masalah Data Mentah

- Duplikasi transaksi — order/revenue terhitung ganda
- Missing email dan harga di banyak baris
- Harga negatif akibat error input
- Format tanggal campur (ISO, slash, teks)
- Nama kota & channel tidak konsisten



Tujuan Pipeline

- Membersihkan data transaksi secara otomatis
- Menghasilkan data siap analisis
- Mencegah data kotor masuk ke output (validation gate)
- Membuat summary report otomatis per kategori

Nilai portofolio: ETL development, data-quality mindset, basic orchestration, dokumentasi GitHub yang rapi.

Audit Data Mentah: raw_orders.csv


130 baris transaksi e-commerce, 6 kategori masalah kualitas data ditemukan sebelum cleaning.

Masalah	Contoh	Dampak
Duplikasi	10 baris duplikat	Order & revenue terhitung ganda
Missing email	~20 baris	Identitas pelanggan tidak lengkap
Missing total harga	~5 baris	Revenue tidak akurat
Harga negatif	~5 baris	Data error memengaruhi laporan
Format tanggal campur	2024-06-15 / 15/06/2024 / Jun 15, 2024	Analisis waktu gagal
Channel & kota inkonsisten	mobile_app vs MOBILE_APP vs Website	Group-by tidak konsisten

Insight: masalah cleaning di latihan ini adalah masalah nyata Data Engineer — bedanya, di industri prosesnya harus otomatis & terjadwal.

ETL Architecture

Prinsip: data tidak boleh di-load sebelum lolos validasi.



Task flow: extract >> transform >> validate >> load — jika validate gagal, load tidak dijalankan.

Cleaning Rules



```
# Hapus duplikasi dan data error
orders = orders.drop_duplicates()
orders = orders[orders['total_harga'] >= 0]

# Isi missing values
orders['customer_email'] = orders[
    'customer_email'].fillna('unknown@placeholder.com')
orders['total_harga'] = orders[
    'total_harga'].fillna(orders['total_harga'].median())

# Standarkan tanggal campur
orders['tanggal_order'] = pd.to_datetime(
    orders['tanggal_order'],
    format='mixed',
    dayfirst=True
)

# Standarkan teks
orders['kota'] = orders['kota'].str.strip().str.title()
orders['channel'] = orders['channel'].str.strip()\
    .str.lower().str.replace(' ', '_')
```

Deduplicate

`drop_duplicates()` menghapus 10 baris ganda

Fix data error

Buang baris dengan harga negatif

Fill missing

Email kosong → placeholder; harga kosong → median

Standardize

Tanggal, casing kota, dan channel diseragamkan

Feature engineering

Turunkan kolom bulan & kategori_harga

Dari Gagal ke Sukses: Bug Format Tanggal

Draf awal Orchestra.ipynb gagal total setelah 3x retry — diperbaiki dan dijalankan ulang sampai sukses.



SEBELUM — FAILED

format='mixed' tanpa dayfirst=True

```
[transform] [FAILED] Error: time data
'11/07/2024' does not match format
'mixed' (match)
[pipeline] [FAILED] Pipeline gagal
```



SESUDAH — COMPLETED

format='mixed' + dayfirst=True bersama-sama

```
[validate] [INFO] Semua 4 check
PASSED ✓
[pipeline] [COMPLETED] Total waktu: 0.04s
```

Pelajaran: kode yang “kelihatan benar” tetap perlu dites ulang setelah perubahan environment — bug ini baru ketahuan saat dijalankan ulang, bukan saat pertama ditulis.

Validation Gate & Outputs

Jika validasi gagal, pipeline berhenti — load tidak dijalankan, error dicatat ke pipeline_log.txt.



Tidak ada duplikat



Tidak ada missing value



Tidak ada harga negatif



Tanggal bertipe datetime



Channel konsisten (≤ 3 nilai unik)

OUTPUT FILES

orders_clean.csv

Dataset bersih siap analisis — 110 baris, 13 kolom.

summary_report.csv


Ringkasan order & revenue per kategori produk.

5 / 5 quality checks PASSED

Orchestration Concept




Validate berfungsi sebagai gate — jika gagal, task load, report, dan notify tidak dijalankan.



Retry

MAX_RETRIES = 3, exponential backoff saat gagal




Logging

pipeline_log.txt mencatat status tiap task



Validation Gate

Clean data wajib lolos quality check sebelum load



Alert

Notify dikirim saat pipeline selesai atau gagal

Airflow DAG (Production-Ready)

dags/etl_ecommerce_dag.py — file yang sebenarnya dipakai Apache Airflow, siap masuk portofolio GitHub.



```
schedule='0 6 * * *'
```

cron — jalan tiap hari jam 6 pagi

```
retries=3 + retry_delay=5min
```

otomatis coba ulang jika gagal

```
email_on_failure=True
```

kirim alert ke tim jika pipeline error

```
catchup=False
```

jangan backfill hari-hari yang terlewat

Dari Laptop ke Cloud

App / CSV / API → Cloud Storage → Transform → Warehouse → Dashboard

Layer	Google Cloud	AWS	Microsoft Azure
Storage	Cloud Storage	S3	Blob Storage
Warehouse	BigQuery	Redshift	Synapse
Transform	Dataflow	Glue	Data Factory
Orchestration	Composer / Airflow	MWAA / Airflow	Monitor

BigQuery: data warehouse serverless, query terabyte dalam hitungan detik, SQL standar, pay-per-query.

Pipeline Run: Sukses

```
nanang@etl-pipeline: ~/orchestrator.py

STARTING ETL PIPELINE
=====

[2026-07-18 11:17:29] [extract] [RUNNING] Attempt 1/3
=== ORDERS INFO ===
Jumlah baris: 130
Duplikasi: 10
Harga negatif: 5
Channel unik: <StringArray>
['MARKETPLACE', 'website', 'mobile_app', 'marketplace', 'Website',
'MOBILE_APP']
Length: 6, dtype: str
[2026-07-18 11:17:29] [extract] [SUCCESS] Selesai dalam 0.01s
[2026-07-18 11:17:29] [transform] [RUNNING] Attempt 1/3
Sebelum: 130 baris -> setelah hapus duplikat: 120 baris
Setelah hapus harga negatif: 110 baris
Missing values setelah fillna: 0
Tipe tanggal: datetime64[us]
Channel setelah standarisasi: <StringArray>
['website', 'mobile_app', 'marketplace']
Length: 3, dtype: str
Distribusi kategori harga:
kategori_harga
sedang    51
besar     49
kecil     10
Name: count, dtype: int64
[2026-07-18 11:17:29] [transform] [SUCCESS] Selesai dalam 0.02s
[2026-07-18 11:17:29] [validate] [RUNNING] Attempt 1/3
=== VALIDASI DATA BERSIH ===
PASS - Tidak ada duplikat
PASS - Tidak ada missing value
PASS - Tidak ada harga negatif
PASS - Tanggal tipe datetime
PASS - Channel konsisten
Hasil: SEMUA LOLOS
[2026-07-18 11:17:29] [validate] [SUCCESS] Selesai dalam 0.0s
[2026-07-18 11:17:29] [load] [RUNNING] Attempt 1/3
Data bersih disimpan: orders_clean.csv (110 baris)


=== SUMMARY PER KATEGORI ===
      kategori  total_orders  total_revenue  avg_revenue
Elektronik         81      435180000.0    5372593.0
Furniture          29      127350000.0    4391379.0

Summary disimpan: summary_report.csv
[2026-07-18 11:17:29] [load] [SUCCESS] Selesai dalam 0.02s
[2026-07-18 11:17:29] [notify] [RUNNING] Attempt 1/3

PIPELINE NOTIFICATION
=====
Status: SUCCESS
Total orders diproses: 110
Total revenue: Rp 562,530,000

[2026-07-18 11:17:29] [notify] [SUCCESS] Selesai dalam 0.0s
[2026-07-18 11:17:29] [pipeline] [COMPLETED] Total waktu: 0.05s
```

130 → 110 baris bersih setelah cleaning — 5 dari 5 quality check PASSED, pipeline COMPLETED tanpa error.



81

order Elektronik

29

order Furniture

Rp 562,5jt

total revenue

Skills Demonstrated & Future Improvements



Skills Demonstrated

Data Cleaning

Data Transformation

Data Validation


Feature Engineering

ETL Development

Workflow Orchestration

Logging & Monitoring

Documentation



Future Improvements

- Integrasi Google BigQuery sebagai warehouse
- Deploy Airflow via Docker
- Slack / email notification pada task notify
- Unit test untuk data quality checks

Recruiter signal: end-to-end ownership, clean GitHub structure, readable documentation, production-aware mindset.

Key Takeaways

- 1 Cleaning harus otomatis dan repeatable
- 2 Validasi wajib dijalankan sebelum load
- 3 Logging mempercepat troubleshooting saat pipeline gagal
- 4 Dokumentasi yang rapi membuat project layak jadi portofolio
- 5 Kode yang “kelihatan benar” tetap perlu dites ulang setelah perubahan environment atau versi library

Terima kasih